DH 1: Sprache und Text

# Annotation: Tools und Pipelines

**Andreas Blombach, Stephanie Evert**
Lehrstuhl für Korpus- und Computerlinguistik
https://www.linguistik.phil.fau.de

Friedrich-Alexander-Universität
Philosophische Fakultät und
Fachbereich Theologie

# Wiederholung

# Korpusannotation: Wortebene

- Jedem (laufenden) Wort wird eine Kategorie zugeordnet
  → sog. Tagging (= Etikettierung)
  - Voraussetzung: Text muss in Wörter zerlegt sein
- Tokenisierung
  - Token = Wort, Zahl, Symbol (😎), Satzzeichen, …
  - im Gegensatz zu Typen = verschiedene Wörter
- Kann schwieriger sein, als man vermuten würde …

```
@Mia1234 #semibk [1] Das schließt direkt an die vorige Frage von
@DieMaJa22 an. In jedem Fall gibt es (wie auch in der Sitzung ...
@Mia1234 #semibk [2]am BspChats gezeigt) starkeHinweise darauf,
dass(wie auch imRealLife) diverseFaktoren die sprVariation
beeinflussen: http://tinyurl.com/3umxkuh
```

https://sites.google.com/site/empirist2015/ (Beißwenger et al. 2016)

# Annotation auf Wortebene

- Zentral: Wortartenannotierung = POS-Tagging
  - Substantiv (noun), Adjektiv, Verb, Adverb, Pronomen, Präposition, Konjunktion, Zahl, Satzzeichen, …
  - engl. POS = part of speech
- Tagset = Kategorienschema
  - meist feinere Unterschiede: Sg/Pl, inf./fin./imp., …

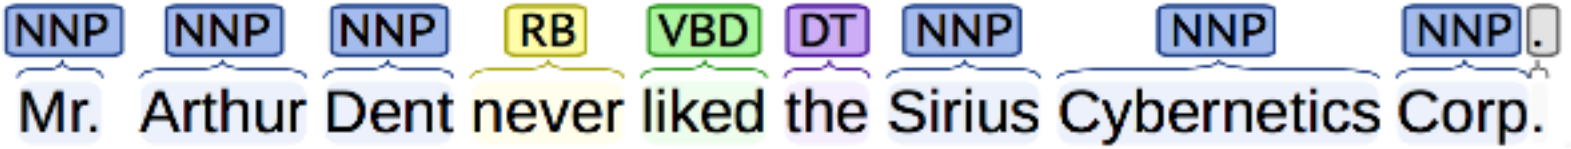


- auch: Lemmatisierung (hier kein Tagset!), semantische Kategorien, emotionale Valenz, Schwierigkeitsgrad (CEFR), …

# Deutsch: STTS-Tagset

Friedrich-Alexander-Universität
Philosophische Fakultät und
Fachbereich Theologie

| | | |
|---|---|---|
| ADJA | attributives Adjektiv | |
| ADJD | adverbiales / prädikatives Adjektiv | |
| ADV | Adverb | *schon, bald, doch* |
| APPR | Präposition / Zirkumposition links | |
| APPRART | Präposition mit Artikel fusioniert | *zum* |
| APPO | Postposition | *zufolge, wegen* |
| APZR | Zirkumposition rechts | *von ... an* |
| ART | bestimmter oder unbestimmter Artikel | |
| CARD | Kardinalzahlen (Ordinalzahl = ADJA) | |
| FM | Fremdsprachliches Material | |
| ITJ | Interjektion | *mhm, ach, tja* |
| KOUI | unterordnende Konj. mit *zu* + Inf | |
| KOUS | unterordnende Konjunktion mit Satz | |
| KON | nebenordnende Konjunktion | *und, oder* |
| KOKOM | Vergleichskonjunktion | *als, wie* |
| NN | normales Nomen | |
| NE | Eigenname | |
| PDS | substituierendes Demonstrativpron. | |
| PDAT | attribuierendes Demonstrativpron. | |
| PIS | substituierendes Indefinitpron. | |
| PIAT | attrib. Indefinitpron. ohne Determiner | |
| PIDAT | attrib. Indefinitpron. mit Determiner | |
| PPER | Personalpronomen (nicht reflexiv) | |
| PPOSS | substituierendes Possessivpronomen | |
| PPOSAT | attribuierendes Possessivpronomen | |
| PRELS | substituierendes Relativpronomen | |
| PRELAT | attribuierendes Relativpronomen | |

| | | |
|---|---|---|
| PRF | reflexives Personalpronomen | |
| PWS | substituierendes Interrogativpron. | |
| PWAT | attribuierendes Interrogativpronomen | |
| PWAV | adverbiales Interrogativ-/Relativpron. | |
| PAV | Pronominaladverb | *dafür, deswegen* |
| PTKZU | *zu* vor Infinitiv | |
| PTKNEG | Negationspartikel | *nicht* |
| PTKVZ | abgetrennter Verbzusatz | *kommt ... an* |
| PTKANT | Antwortpartikel | *ja, nein, danke* |
| PTKA | Partikel bei Adjektiv/Adverb | *am, zu* |
| TRUNC | Kompositions-Erstglied | *Unter- und ...* |
| VVFIN | finites Verb, voll (= lexikalisch) | |
| VVIMP | Imperativ, voll | |
| VVINF | Infinitiv, voll | |
| VVIZU | Infinitiv mit *zu*, voll | |
| VVPP | Partizip Perfekt, voll | |
| VAFIN | finites Hilfsverb | |
| VAIMP | Imperativ, Hilfsverb | |
| VAINF | Infinitiv, Hilfsverb | |
| VAPP | Partizip Perfekt, Hilfsverb | |
| VMFIN | Finites Modalverb | |
| VMINF | Infinitiv, Modalverb | |
| VMPP | Partizip Perfekt, Modalverb | |
| XY | Nichtwort mit Sonderzeichen | *3:7, H2O* |
| $, | Komma | *,* |
| $. | Satzbeendende Interpunktion | *. ? ! ; :* |
| $( | sonstige Satzzeichen (intern) | *– [ ] ( )* |

# Englisch: Penn-Tagset (modifiziert)

Friedrich-Alexander-Universität
Philosophische Fakultät und
Fachbereich Theologie

| | | |
|---|---|---|
| CC | Coordinating conjunction | |
| CD | Cardinal number | |
| DT | Determiner | |
| EX | Existential *there* | |
| FW | Foreign word | |
| IN | Preposition / subordinating conjuction | |
| IN/that | Subordinating conjunction *that* | |
| JJ | Adjective (positive) | |
| JJR | Adjective (comparative) | |
| JJS | Adjective (superlative) | |
| LS | List item marker | |
| MD | Modal verb | |
| NN | Noun, singular or mass | |
| NNS | Noun, plural | |
| NP | Proper noun, singular | |
| NPS | Proper noun, plural | |
| PDT | Predeterminer | |
| POS | Possessive ending (*'s*) | |
| PP | Personal pronoun | |
| PP$ | Possessive pronoun | |
| RB | Adverb | |
| RP | Particle | |
| SYM | Symbol (mathemathical/scientific) | |
| TO | *to* (any usage) | *fly to Paris, ready to go, ...* |
| UH | Interjection | |
| # | Pound sign | *£* |
| $ | Dollar sign | *$* |

| | | |
|---|---|---|
| VB | Verb *be*, base form | |
| VBD | Verb *be*, past tense | |
| VBG | Verb *be*, gerund/progressive | |
| VBN | Verb *be*, past participle | |
| VBP | Verb *be*, non-3rd pers. sg. present | |
| VBZ | Verb *be*, 3rd pers. sg. present tense | |
| VH | Verb *have*, base form | |
| VHD | Verb *have*, past tense | |
| VHG | Verb *have*, gerund/progressive | |
| VHN | Verb *have*, past participle | |
| VHP | Verb *have*, non-3rd pers. sg. present | |
| VHZ | Verb *have*, 3rd pers. sg. present tense | |
| VV | Lexical verb, base form | |
| VVD | Lexical verb, past tense | |
| VVG | Lexical verb, gerund/progressive | |
| VVN | Lexical verb, past participle | |
| VVP | Lexical verb, non-3rd pers. sg. present | |
| VVZ | Lexical verb, 3rd pers. sg. present tense | |
| WDT | Wh-determiner | |
| WP | Wh-pronoun | |
| WP$ | Possessive wh-pronoun | |
| WRB | Wh-adverb | |
| SENT | Sentence-final punctuation | *. ! ?* |
| , | Comma | *,* |
| : | Colon, semi-colon | *: ;* |
| ( ) | Comma | *( [ ] )* |
| `` '' | Comma | *“...” ‘...’ "* |

# Universal-Dependencies-Tags (sprachübergreifend)

| Open class words | Closed class words | Other |
|---|---|---|
| ADJ | ADP | PUNCT |
| ADV | AUX | SYM |
| INTJ | CCONJ | X |
| NOUN | DET | |
| PROPN | NUM | |
| VERB | PART | |
| | PRON | |
| | SCONJ | |

- ADJ: adjective
- ADP: adposition
- ADV: adverb
- AUX: auxiliary
- CCONJ: coordinating conjunction
- DET: determiner
- INTJ: interjection
- NOUN: noun
- NUM: numeral
- PART: particle
- PRON: pronoun
- PROPN: proper noun
- PUNCT: punctuation
- SCONJ: subordinating conjunction
- SYM: symbol
- VERB: verb
- X: other

# Segmente und Strukturen

- Erkennung von speziellen Wortfolgen (Segmenten bzw. spans) und ihre Kategorisierung
- z.B. Eigennamen (NER = named entity recognition)

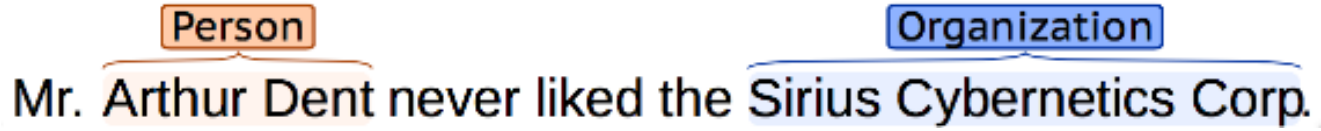


  - Fallen Ihnen noch weitere Beispiele für interessante Segmente ein?

- Kann auch als Tagging operationalisiert werden

| O | B-PERS | I-PERS | O | O | O | B-ORG | I-ORG | I-ORG |
|---|---|---|---|---|---|---|---|---|
| Mr. | Arthur | Dent | never | liked | the | Sirius | Cybern. | Corp. |

# Strukturen: Parsing

- Erkennung der Satzstruktur = Parsing
- Phrasenstruktur als baumförmige Hierarchie

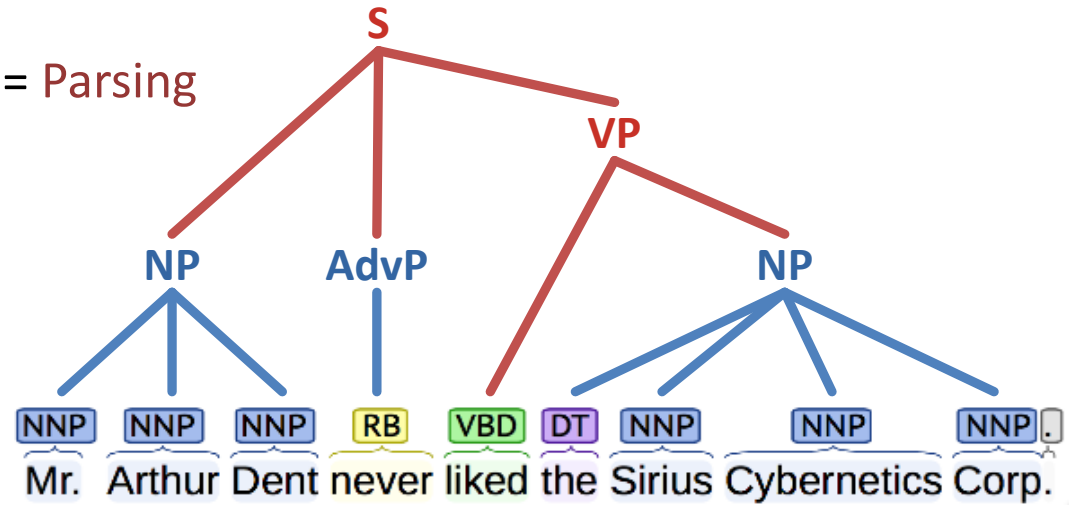


- alternativ: „minimale“ Phrasen als flache Segmente → Chunk-Parsing

- Dependenz-Parsing findet direkte Abhängigkeiten zwischen Wörtern

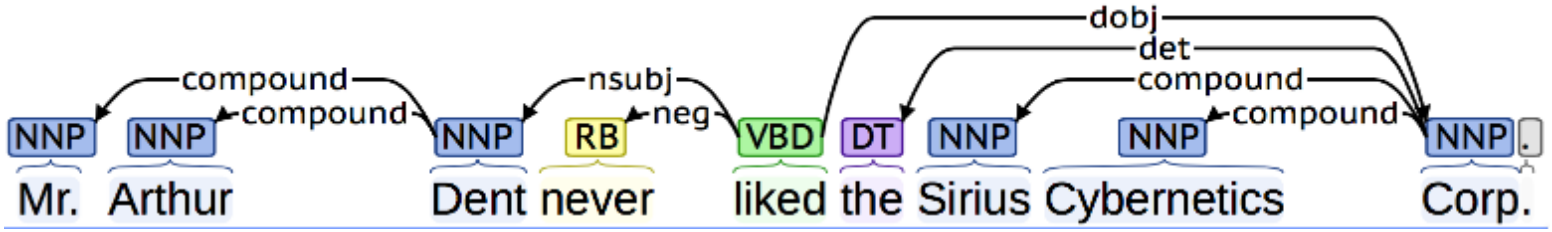

# Beispiel: Syntaktische Analyse

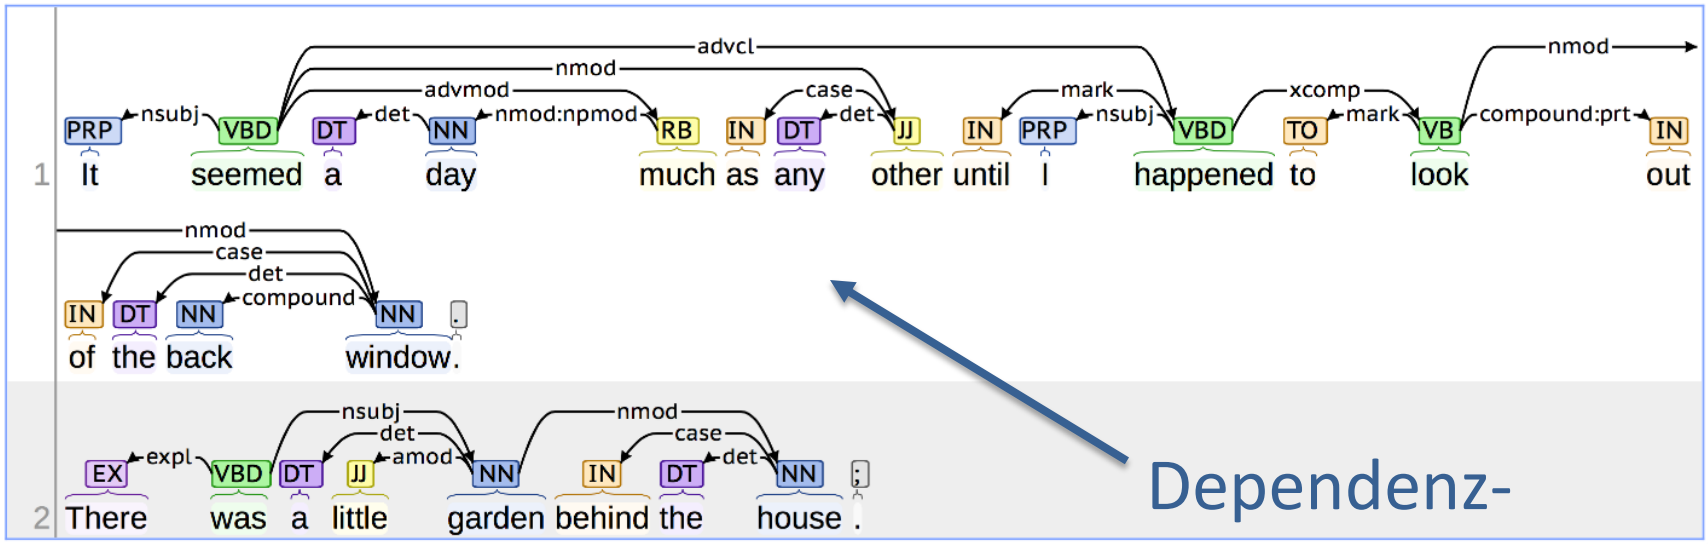


Dependenz-Graph

Zum Ausprobieren:

- http://corenlp.run/
- https://explosion.ai/demos/displacy

# Manuelle Annotation

- Kleine Korpora werden oft manuell annotiert
  - z.B. digitale Editionen, Reden eines Präsidenten, …
- Annotationsschema und -kategorien (Tagset)
- Richtlinien (Guidelines)
  - detaillierte Beschreibung und Abgrenzung der Zielkategorien (z.B. für STTS)
  - zusätzlich: Beispielsammlung für schwierige Einzelfälle
- Annotationswerkzeuge (meist Web-basiert)
  - z.B. INCEpTION (https://inception-project.github.io), Prodigy (https://prodi.gy)
- Inter-Annotator Agreement (IAA)
  - wichtig! – überprüft Reliabilität und Validität der Annotation
  - Flüchtigkeitsfehler vs. systematische Differenzen
  - Adjudikation für Endfassung der Annotation

# Automatische Annotation

- Für größere Korpora ist eine manuelle Annotation zu teuer und zeitaufwendig

- Auch in den Digital Humanities …
  - Romane von Charles Dickens — ca. 4 Mio. Wörter
  - Deutsches Gutenberg-Archiv — > 100 Mio. Wörter
  - Early English Books (EEBO) — > 500 Mio. Wörter
  - Times Online 1780–1900 — ca. 4.000 Mio. Wörter

# Automatische Annotation

- Erfolgreichster Ansatz: maschinelle Lernverfahren
  - ab ca. 1990 Einsatz von statistischen Modellen („statistical revolution“)
  - aktuell große Fortschritte mit Deep Learning
- Trainingskorpus (manuell annotiert)
  - wichtig: Konsistenz der Annotationen (→ IAA)
  - Flüchtigkeitsfehler scheinen weniger problematisch
- Evaluation auf separatem Testkorpus
  - Gefahr der Überanpassung an das Trainingskorpus
  - zusätzliches development set für Optimierung der Lernverfahren (tuning)
  - Kreuzvalidierung (cross-validation) nutzt alle Daten für Training & Evaluation

- Weiterführend: https://web.stanford.edu/~jurafsky/slp3/

# Repräsentationsformat: XML

```
<?xml version="1.0" encoding="UTF-8"?>
<corpus>
  <story title="The Garden">
    <p>
      <s>
        <token pos="PP"  lemma="it">It</token>
        <token pos="VBD" lemma="seem">seemed</token>
        <token pos="DT"  lemma="a">a</token>
        <token pos="NN"  lemma="day">day</token>
        <token pos="RB"  lemma="much">much</token>
        <token pos="IN"  lemma="as">as</token>
        <token pos="DT"  lemma="any">any</token>
        <token pos="JJ"  lemma="other">other</token>
        <token pos="IN"  lemma="until">until</token>
        <token pos="PP"  lemma="I">I</token>
         ...
      </s>
    </p>
  </story>
</corpus>
```

# Repräsentationsformat: Vertical text (.vrt)

```
<corpus>
<text title="The Garden" author="Stefan Evert" author_sex="male"
      date="1991-08-05">
<p num="1">
<s>
It        PP    it
seemed    VBD   seem
a         DT    a
day       NN    day
much      RB    much
as        IN    as
any       DT    any
other     JJ    other
until     IN    until
I         PP    I
...
</s>
</p>
</text>
</corpus>
```

# Repräsentationsformat: CoNLL-Format(e)

```
# story: "The Garden"
# paragraph #1
1    It        PP    it
2    seemed    VBD   seem
3    a         DT    a
4    fine      JJ    fine
5    day       NN    day
6    .         SENT  .

1    There     EX    there
2    was       VBD   be
3    an        DT    a
4    elephant  NN    elephant
5    .         SENT  .

# this is the end of the file
```

aktuell: CoNLL-U (https://universaldependencies.org/format.html)

# Übersicht: Tools

# Manuelle Annotation: Tools

- WebAnno / INCEpTION (linguistischer Fokus):
  - https://webanno.github.io/webanno/documentation/
  - https://www.youtube.com/user/webanno
  - https://inception-project.github.io
  - https://youtube.com/playlist?list=PL5Hz5pttaj96SlXHGRZf8KzlYvpVHIoL-

- prodigy (linguistischer Fokus):
  - https://prodi.gy

- CATMA (literaturwissenschaftlicher Fokus)
  - z.B. Annotation von wörtlicher und indirekter Rede
  - https://fortext.net/routinen/lerneinheiten/manuelle-annotation-mit-catma

# Automatische Annotation: komplette Pipelines (1)

- Stanford CoreNLP (https://stanfordnlp.github.io/CoreNLP/)
  - langlaufendes Projekt, Java
  - Tokenisierung, POS-Tagging, Lemmatisierung, NER, Parsing, Koreferenzauflösung, Sentiment-Analyse, …

- Stanza (https://stanfordnlp.github.io/stanza/)
  - Python, Deep Learning, Interface zu CoreNLP (z.B. für Koreferenzauflösung relevant)
  - Tokenisierung, POS-Tagging, Lemmatisierung, NER, Dependenzparsing, Sentiment-Analyse

- spaCy – „fastest in the world“ (https://spacy.io)
  - Python, Deep Learning
  - Tokenisierung, POS-Tagging, Lemmatisierung, NER, Dependenzparsing

# Automatische Annotation: komplette Pipelines (2)

- Apache OpenNLP (https://opennlp.apache.org/)
  - Java
  - Tokenisierung, POS-Tagging, Lemmatisierung, NER, Dependenzparsing, Koreferenzauflösung

- UDPipe (http://ufal.mff.cuni.cz/udpipe)
  - C++/Python, als Bibliothek für diverse C++, C#, Python, Perl und Java verfügbar
  - *UD* steht für *Universal Dependencies*
  - Tokenisierung, POS-Tagging, Lemmatisierung, Dependenzparsing

# Automatische Annotation: Tokenisierung und Tagging

- reine Tokenisierer
  - Python: SoMaJo (DE, EN)
  - generischer Tokenisierer: Unitok
  - Tokenisierer von NLTK ist bestenfalls mittelmäßig
  - wichtig: Tokenisierung und weitere Verarbeitung müssen kompatibel sein!
- Part-of-speech-Tagger (oft mit eigenem Tokenisierer)
  - TreeTagger (schnell, einfach, viele Sprachen, inkl. Lemmatisierung)
  - RNNTagger (Deep-Learning-Nachfolger des TreeTaggers, Python, inkl. Lemm.)
  - Python: SoMeWeTa (DE, EN, FR)
  - Twitter data (EN): TweetNLP
  - und viele weitere spezialisierte Tokenisierer und Tagger für diverse Sprachen
- Eigene Pipeline im Webservice erstellen: https://weblicht.sfs.uni-tuebingen.de/weblichtwiki/index.php/Main_Page