Keywords und Kollokate

Statistik für Korpuslinguisten Sommersemester 22

Philipp Heinrich

Lehrstuhl für Korpus- und Computerlinguistik Friedrich-Alexander-Universität Erlangen-Nürnberg philipp.heinrich@fau.de

Erlangen, 31.05.12022






Keywords

- Keywords sind Wörter, die in einem gegebenen Korpus überdurchschnittlich oft vorkommen im Vgl. zur Häufigkeit in einem Referenzkorpus
- Assoziationsmaße quantifizieren den Vergleich mittels einer einzelnen reellen Zahl, basierend auf Intuition und/oder statistischen Verfahren
- Keyness ist ein textuelles, kein sprachliches Feature
 - gesprochene Sprache vs. geschriebene Sprache
 - soziale Medien vs. Zeitungen
 - ► Hochliteratur vs. Groschenromane
 - ▶ links-liberale Zeitungen vs. rechts-konservative Zeitungen
 - ▶ Grüne vs. AfD
 - **.** . . .
- Anwendung bspw. in der Diskursanalyse, Indexerstellung, ...

Keywords in CQPweb



Kollokate

- Kollokate eines Wortes (dem Knoten, oder engl. node) sind Wörter, die häufig in dessen Umgebung auftreten (Ko-Okkurrenz)
- Einblick in die Semantik des Wortes, vgl. Firth's (1957) distributional hypothesis: You shall know a word by the company it keeps!
- hier: Kollokation als Phänomen, das in Korpora empirisch beobachtbar ist
 - Kollokate von "Atomkraft" im GermaParl
 - ► Kollokate von "Impfung" auf Twitter
- Anwendung bspw. in der Diskursanalyse, Lexikographie, . . .
- Kollokate ≠ Mehrworteinheiten, Idiome, Phraseologismen, . . .

4 / 16

Kollokate von bucket (noun)

noun	f	verb	f	adjective	f
water	183	throw	36	large	37
spade	31	fill	29	single-record	5
plastic	36	randomize	9	cold	13
slop	14	empty	14	galvanized	4
size	41	tip	10	ten-record	3
тор	16	kick	12	full	20
record	38	hold	31	empty	9
bucket	18	carry	26	steaming	4
ice	22	put	36	full-track	2
seat	20	chuck	7	multi-record	2
coal	16	weep	7	small	21
density	11	pour	9	leaky	3
brigade	10	douse	4	bottomless	3
algorithm	9	fetch	7	galvanised	3
shovel	7	store	7	iced	3
container	10	drop	9	clean	7
oats	7	pick	11	wooden	6

fensterbasierte Kollokate in CQPweb



	Ther	re are 703 different lemma (treetagger)	s in the collocation database for this query (Qu	ery "Atomkraft" returned 306 matches in 176	different texts)	[0.349 seconds - retrieved from cache]
No.	Lemma (TreeTagger)	Total no. in whole corpus	Expected collocate frequency	Observed collocate frequency	In no. of texts	Log Ratio (filtered)
1	Ausstieg	587	0.055	34	29	9.367
2	raus	245	0.023	<u>14</u>	8	9.346
3	aussteigen	360	0.034	<u>18</u>	17	9.143
4	Kohle	343	0.032	Z	7	7.806
5	Nutzung	1,282	0.119	24	20	7.679
6	billig	695	0.065	Z	4	6.772
7	Energieversorgung	603	0.056	<u>5</u>	5	6.489
8	friedlich	971	0.09	<u>5</u>	4	5.797
9	<u>rein</u>	1,520	0.142	Z	5	5.635
10	zurück	2,406	0.224	5	5	4.483
11	aus	46,045	4.287	87	61	4.346
12	Risiko	2,663	0.248	5	4	4.337

textuelle Kookkurrenz

textual cooccurrence / segment-based cooccurrence

A vast deal of coolness and a peculiar degree of judgement, are requisite in catching a <u>hat</u> .	hat	_
A man must not be precipitate, or he runs over it;	_	over
he must not rush into the opposite extreme, or he loses it altogether.	_	_
There was a fine gentle wind, and Mr. Pickwick's <u>hat</u> rolled sportively before it.	hat	_
The wind puffed, and Mr. Pickwick puffed, and the <u>hat</u> rolled <i>over</i> and <i>over</i> as merrily as a lively porpoise in a strong tide;	hat	over

Philipp Heinrich

textuelle Kookkurrenz (Satzfenster)

	$w_2 \in S$	$w_2 \not\in S$	
$w_1 \in S$	O_{11}	O_{12}	=
$w_1 \not\in S$	O_{21}	O_{22}	

$$= f_2 = N$$

	over ∈ S	over ∉ <i>S</i>	
$hat \in S$	1	2	= 3
hat ∉ S	1	1	

$$= 2$$
 $= 5$

Oberflächenkookkurrenz

surface cooccurrence / distance-based cooccurrence

fensterbasiert, abgeschnitten an entsprechenden Grenzen

A vast deal of coolness and a peculiar degree of judgement, are <u>trequisite</u> in catching a **hat**₁. A man must not be precipitate, or he runs over it; he must not rush into the opposite extreme, or he loses it altogether. [...] There was a fine gentle <u>wind</u>, and Mr. <u>Pickwick's hat rolled sportively before it</u>₁. The wind puffed, and Mr. <u>Pickwick puffed</u>, and the <u>hat rolled over and over</u>₁ as merrily as a lively porpoise in a strong tide; and on it might have *rolled*, far beyond Mr. Pickwick's reach, had not its course been providentially stopped, just as that gentleman was on the point of resigning it to its fate.

Oberflächenkookkurrenz (L4, R4)

	w_2	$\neg w_2$
near(w ₁)	O_{11}	O_{12}
$\neg near(w_1)$	O_{21}	O_{22}

 $= f_2$

 $\approx k \cdot f_1$

$$\begin{array}{c|cccc}
 & \text{roll} & \neg \text{roll} \\
\hline
 near(\text{hat}) & 2 & 18 & = 20 \\
\hline
 \neg near(\text{hat}) & 1 & 87 & \\
\hline
\end{array}$$

$$= N - f_1$$

$$= 108$$

Kollokate

syntaktische Kookkurrenz

syntactic cooccurrence / relational cooccurrence

Ausnutzung syntaktischer Strukturen

In an open barouche [...] stood a stout old gentleman, in a blue coat and bright buttons, corduroy breeches and top-boots; two young ladies in scarfs and feathers; a young gentleman apparently enamoured of one of the young ladies in scarfs and feathers; a lady of doubtful age, probably the aunt of the aforesaid; and [...]

open stout gentleman old blue coat bright young young young doubtful barouche gentleman lady

Philipp Heinrich

syntaktische Kookkurrenz

	$* w_2 $	$* \neg w_2$	
$w_1 *$	O_{11}	O_{12}	=
$\neg w_1 *$	O_{21}	O_{22}	

$$= f_2 = N$$

	* gent.	∗ ¬gent.	
young *	1	2	= 3
¬young *	2	4	

$$=3$$

Kontingenztabelle (beobachtete Häufigkeiten)

	word	other words	
corpus ₁	$O:=O_{11}$	O_{12}	$=R_1$
corpus ₂	O ₂₁	O_{22}	$=R_2$
	$= C_1$	$= C_2$	= N

Indifferenztabelle (erwartete Häufigkeiten bei Unabhängigkeit)

	word	other words	
corpus ₁	$E:=E_{11}=\tfrac{R_1C_1}{N}$	$E_{12} = \frac{R_1 C_2}{N}$	$=R_1$
corpus ₂	$E_{21} = \frac{R_2 C_1}{N}$	$E_{22} = \frac{R_2 C_2}{N}$	$=R_2$
	$= C_1$	$= C_2$	= N

Assoziationsmaße

Quantifikation der Abweichung:

	word	other words	
corpus ₁	O vs. E	O_{12} vs. E_{12}	$=R_1$
corpus ₂	O_{21} vs. E_{21}	O_{22} vs. E_{22}	$=R_2$
	$= C_1$	$= C_2$	= N

- $log-ratio = log \frac{O_{11}/R_1}{O_{21}/R_2}$
- $MI = log_2 O/E$
- t-score = $\frac{O-E}{\sqrt{O}}$

- $LLR = 2\sum_{ij} O_{ij} \log \frac{O_{ij}}{E_{ij}}$
- $\chi^2 = \sum_{ij} \frac{(O_{ij} E_{ij})^2}{E_{ii}}$
- . . .

Software

- Berechnung der Assoziationsmaße unkompliziert
 - ▶ R: einfache Datensatzmanipulation
 - Python: association-measures
 - ► CLI (Perl): UCS toolkit
- korrektes und effizientes Zählen am besten nach Korpusindexierung in CWB
 - ▶ R: PolmineR
 - ▶ Python: cwb-ccc
 - ► GUI (PHP): CQPweb